ԳԼՈՒԽ 1. ՆԵՅՐՈՆԱՅԻՆ ՑԱՆՑԻ ԿԱՌՈՒՑՎԱԾՔԸ

1.1 Նեյրոնային ցանցերի օգտագործումը ձեռագիր թվերի ճանաչման համար

Դիտարկենք ձեռագիր թվերի հետևյալ հաջորդականությունը.

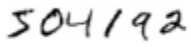

Մարդիկ հեշտությամբ ճանաչում են այս թվերը, ինչպես՝ 504192, բայց ճանաչման դժվարությունը ակնհայտ է դառնում, երբ փորձում ենք գրել համակարգչային ծրագիր՝ նման թվերի ճանաչման համար:

Նեյրոնային ցանցի գաղափարը հետևյալն է: Վերցնենք մեծ քանակությամբ ձեռագիր թվեր, որոնք հայտնի են որպես ուսուցողական օրինակներ՝

ապա մշակենք համակարգ, որը կկարողանա սովորել հիմք ընդունելով այդ օրինակները: Այլ խոսքով՝ նեյրոնային ցանցը օգտագործում է այդ օրինակները, որպեսզի կարողանա ինքնաշխատ կերպով հայտնաբերել ձեռագիր թվերի ճանաչման օրինաչափությունները: Ավելին, ավելացնելով ուսուցողական օրինակների քանակը, ցանցը կարող է ավելի շատ տեղեկություն ստանալ ձեռագրերի մասին և բարելավել իր ճշգրտությունը:

<u>Պերսեպտրոններ (perceptron)</u>

Պերսեպտրոնի աշխատանքը նման է մարդու ուղեղի բջիջի՝ նեյրոնի աշխատանքին:

Պերսեպտրոնն ընդունում է մի քանի բինարային մուտքային արժեքներ՝ x1, x2, … և արտադրում է մեկ բինարային արդյունք.

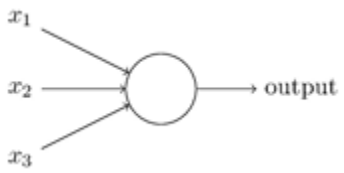

Ցուցադրված օրինակում, պերսեպտրոնն ունի երեք մուտքային արժեք՝ x1, x2, x3: Այն կարող է ավելի շատ կամ ավելի քիչ մուտքային արժեքներ ունենալ: Դա ապացուցելու համար ներմուծենք կշիռներ՝ w1, x2, … (իրական թվեր), որոնք արտահայտում են համապատասխան մուտքային արժեքների ազդեցության կարևորությունը ելքային արժեքի վրա: Նեյրոնի ելքային արժեքը՝ 0 կամ 1, որոշվում է ըստ հետևյալ գումարի՝

$$\Sigma_j w_j x_j \tag{1}$$

որն ավելի փոքր / մեծ է, քան նախօրոք սահմանված շեմային արժեքը: Շեմային արժեքը նեյրոնի պարամետր է, որն ինչպես կշիռները, իրական թիվ է: Ելքային արժեքի ավելի ճշգրիտ մաթեմատիկական արտահայտությունը կլինի՝

$$output = \begin{cases} 0, & \sum_j w_j x_j \leq \text{շեմ} \\ 1, & \sum_j w_j x_j > \text{շեմ} \end{cases} \tag{2}$$

Այսպիսով, կարելի է ասել, որ պերսեպտրոնը մի սարք է, որը որոշումներ է կայացնում՝ կշռելով մուտքային արժեքները:

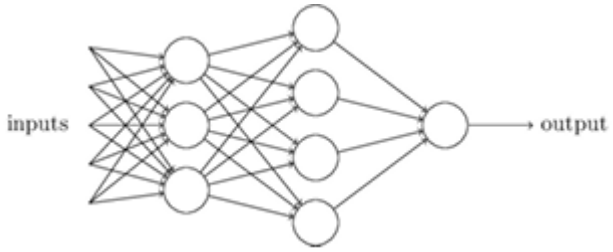

Այս ցանցում, պերսեպտրոնների առաջին սյունը՝ կկոչենք պերսեպտրոնների առաջին շերտ: Այդ շերտը կայացնում է երեք շատ պարզ որոշում՝ կշռելով մուտքային արժեքները: Ինչ վերաբերում է երկրորդ շերտի պերսեպտրոններին՝ այդ պերսեպտրոններից յուրաքանչյուրը որոշում է կայացնում՝ կշռելով առաջին շերտի ելքային արժեքները: Այս կերպ, պերսեպտրոնների բազմաշերտ ցանցը կարող է ընդգրկվել բարդ որոշումների կայացման մեջ:

Այժմ ավելի պարզ նկարագրենք պերսեպտրոնները:

$$\sum_j w_j x_j > շ.ա \text{ (շեմային արժեք)} \quad (3)$$

պայմանը բարդ է և մենք կարող ենք կատարել երկու նշանակային փոփոխություն այն պարզեցնելու համար: Առաջինը գրենք՝ $\sum wjxj$ յ , որպես կետ $w \cdot x = \sum wjxj$ յ , որտեղ w և x վեկտորները՝ համապատասխանաբար կշիռներն ու մուտքային արժեքներն են: Երկրորդ փոփոխությունը՝ շեմը տեղափոխելն է հավասարման մյուս կողմ և նշանակելն է b -ով: Այն կանվանենք պերսեպտրոնի շեղում (bias)՝ b ≡ − շ.ա : Օգտվելով այս նշանակումից արտահայտությունը կարող ենք գրել հետևյալ կերպ՝

$$output = \begin{cases} 0, & w \cdot x + b \leq 0 \\ 1, & w \cdot x + b > 0 \end{cases} \quad (4)$$

Այսուհետ, շեմային արժեքին կանվանենք շեղում:

Մինչ այժմ, մենք պատկերում էինք x1 և x2 մուտքային արժեքներն ինչպես փոփոխականներ, սակայն մենք կարող ենք x1 և x2 մուտքային արժեքները պատկերել նաև, որպես պերսեպտրոնների ցանցի մուտքային արժեքներից կառուցված շերտ:

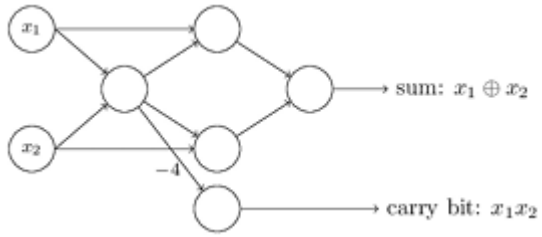

Նման պատկերման դեպքում ստացվում է, որ առաջին շերտի համար չունենք մուտքային արժեքներ, սակայն x1, x2 -ից յուրաքանչյուրի համար կան ելքային արժեքներ

Դա դեռ չի նշանակում, որ պերսեպտրոնները չունեն մուտքային արժեքներ:

Դա ապացուցելու համար, ենթադրենք, որ ունենք մուտքային արժեքներ չունեցող պերսեպտրոն: Այդ պարագայում, գումարը միշտ կլինի՝ $\sum_J wjxj = 0$,և հետևաբար պերսեպտրոնի ելքային արժեքը կլինի՝

$$\begin{cases} 1, \text{երբ } b > 0 \\ 0, \text{երբ } b \leq 0 \end{cases}$$

Սիգմոիդ նեյրոններ (Sigmoid neurons)

Ենթադրենք, ունենք պերսեպտրոնների ցանց, որը ցանկանում ենք օգտագործել որոշակի խնդիր լուծելու համար: Օրինակ, ցանցի մուտքային արժեքները կարող են լինել թվի ձեռագիր պատկերի սկանավորված, հում պիքսելային տվյալները: Եվ մենք ցանկանում ենք, որ ցանցը սովորի կշիռներն ու շեղումներն այնպես, որ ցանցի ելքը ճիշտ դասակարգի թիվը: Որպեսզի տեսնենք, թե ինչպես կարող է աշխատել ուսուցումը, ենթադրենք, որ մենք փոքր փոփոխություն ենք կատարում ցանցի որևէ կշռի / շեղման մեջ: Մենք ցանկանում ենք, որ կշռի այս փոքր փոփոխությունը առաջացնի միայն փոքր համապատասխան փոփոխություն ցանցի ելքում: Այս հատկությունը կարող է դարձնել ուսուցումը հնարավոր:

Ներքևում պատկերված գծապատկերն արտահայտում է թե ինչ ենք ուզում (ակնհայտ է, որ այս ցանցը չափազանց պարզ է ձեռագրի ճանաչման համար):

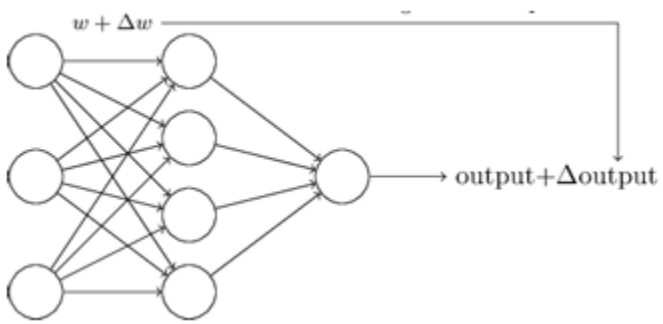

Եթե ճիշտ լիներ, որ կշռի (կամ շեղման) փոքր փոփոխությունը առաջացնում է միայն փոքր փոփոխություն ելքում, ապա մենք կարող էինք օգտագործել այս փաստը՝ կշիռները և շեղումները փոփոխելու համար, որպեսզի մեր ցանցը աշխատի այնպես, ինչպես ցանկանում ենք:

Իրականում, ցանցի ցանկացած պերսեպտրոնի կշռի կամ շեղման փոքր փոփոխությունը երբեմն կարող է առաջացնել այդ պերսեպտրոնի ելքի ամբողջական շրջում, օրինակ՝ 0-ից 1: Այդ շրջումը կարող է առաջացնել ցանցի մյուս մասի վարքագծի ամբողջական փոփոխություն: Այդ պատճառով բարդ է տեսնել, թե ինչպես կարելի է աստիճանաբար փոփոխել կշիռներն ու շեղումները, որպեսզի ցանցը ավելի մոտ լինի ցանկալի վարքագծին:

Մենք կարող ենք հաղթահարել այս խնդիրը՝ ներկայացնելով արհեստական նեյրոնի նոր տեսակ, որը կոչվում է սիգմոիդ նեյրոն: Սիգմոիդ նեյրոնները նման են

պերսեպտրոններին, բայց փոփոխված են այնպես, որ կշիռների և շեղման փոքր փոփոխությունները առաջացնում են միայն փոքր փոփոխություն նրանց ելքում: Սա այն կարևոր փաստն է, որը թույլ կտա սիգմոիդ նեյրոնների ցանցին սովորեցնել:

Մենք սիգմոիդ նեյրոնները կնկարագրենք նույն կերպ, ինչպես նկարագրեցինք պերսեպտրոնները:

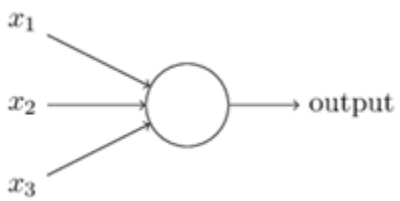

Ճիշտ ինչպես պերսեպտրոնը, սիգմոիդ նեյրոնն ունի մուտքային արժեքներ՝ x1, x2, ...: Բայց 0 կամ 1 լինելու փոխարեն, այս մուտքային արժեքները կարող են լինել (0,1) միջակայքի ցանկացած արժեք: Այսպիսով, օրինակ, 0.638... արժեքը վավեր մուտք է սիգմոիդ նեյրոնի համար:

Ինչպես պերսեպտրոնը, սիգմոիդ նեյրոնն ունի կշիռներ յուրաքանչյուր մուտքային արժեքի համար՝ w1, w2, ..., և ընդհանուր շեղում՝ b: Բայց ելքային արժեքը 0 կամ 1 չէ: Փոխարենը, այն արտահայտվում է այսպես՝ $\sigma(w \cdot x + b)$, որտեղ σ -ն սիգմոիդ ֆունկցիա է և սահմանվում է՝

$$\sigma(z) \equiv \frac{1}{1+e^{-z}} \tag{5}$$

Ավելի հստակ ասած, սիգմոիդ նեյրոնի ելքը՝ x1, x2, ... մուտքային արժեքներով, w1, w2, ... կշիռներով և b շեղումով կունենա հետևյալ տեսքը.

$$\frac{1}{1+\exp\left(-\sum_j w_j x_j - b\right)} \tag{6}$$

Պերսեպտրոնների մոդելի հետ նմանությունը հասկանալու համար ենթադրենք, որ $z \equiv w \cdot x + b$ -ը մեծ դրական թիվ է: Այդ դեպքում $e - z \approx 0$ և $\sigma(z) \approx 1$: Այլ կերպ ասած, երբ $z = w \cdot x + b$ -ն մեծ է և դրական, ապա սիգմոիդ նեյրոնի ելքը մոտավորապես 1 է, ճիշտ այնպես, ինչպես կլիներ պարսեպտրոնի համար: Այժմ, ենթադրենք, որ $z = w \cdot x + b$ շատ մեծ է և բացասական: Այդ դեպքում $e - z \rightarrow \infty$ և $\sigma(z) \approx 0$: Այսպիսով, երբ $z = w \cdot x + b$ շատ մեծ և բացասական է, սիգմոիդ նեյրոնի

վարքագիծը նույնպես մոտավորապես համապատասխանում է պերսեպտրոնի վարքագծին: Միայն այն ժամանակ, երբ $w \cdot x + b$ -ն ունի հստակ չափ, կարող է լինել մեծ շեղում պերսեպտրոնի մոդելից:

Այժմ խոսենք σ-ի անալիտիկ ձևի մասին: Իրականում, σ- ի ճշգրիտ ձևը այնքան էլ կարևոր չէ, իսկապես կարևորը ֆունկցիայի ձևն է, երբ այն պատկերվում է գծագրի միջոցով.

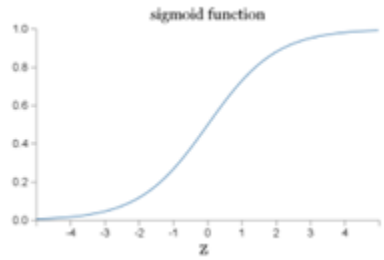

Իսկ սա աստիճանային ֆունկցիայի հարթեցված տարբերակն է.

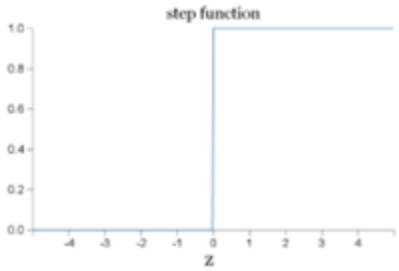

Եթե σ -ն իրականում աստիճանային ֆունկցիա լիներ, ապա սիգմոիդ նեյրոնը կլիներ պերսեպտրոն, քանի որ ելքը կլիներ 1 կամ 0՝ կախված $w \cdot x + b$ -ի դրական կամ բացասական լինելուց: Իրականում, երբ $w \cdot x + b = 0$՝ պերսեպտրոնի ելքը 0 է, մինչդեռ աստիճանային ֆունկցիայի ելքը 1 է: Մենք պետք է փոփոխենք աստիճանային ֆունկցիան այդ կետում: Այսպիսով, օգտագործելով իրական σ ֆունկցիան, մենք ստանում ենք հարթեցված պերսեպտրոն: σ-ի հարթությունը նշանակում է, որ կշիռների՝ Δw_j և շեղման՝ Δb, փոքր փոփոխությունները, կհանգեցնեն նեյրոնի ելքի փոքր փոփոխության՝ Δoutput: Մաթեմատիկորեն, $\Delta output$ -ը մոտարկվում է հետևյալ կերպ՝

$$\Delta \text{output} \approx \sum_j \frac{\partial \text{output}}{\partial w_j} \Delta w_j + \frac{\partial \text{output}}{\partial \text{b}} \Delta b \qquad (7)$$

որտեղ գումարը գերազանցում է բոլոր w_j կշիռները, իսկ $\frac{\partial output}{\partial w_j}$, $\frac{\partial output}{\partial b}$ ցույց են տալիս մուտքի մասնակի ածանցյալները՝ համապատասխան կշռի և շեղման համար: $\Delta output$-ը կշիռների՝ Δw_j, և շեղման՝ Δb, փոփոխությունների գծային ֆունկցիան է: Այս գծայնությունը հեշտացնում է ընտրել կշիռների և շեղումների փոքր փոփոխությունները՝ ելքի ցանկացած ցանկալի փոքր փոփոխություն ստանալու համար:

Այսպիսով, պերսեպտրոնների և սիգմոիդ նեյրոնների միջև մեծ տարբերություններից մեկն այն է, որ սիգմոիդ նեյրոնների ելքային արժեքները պարզապես 0 կամ 1 չեն: Դրանց ելքային արժեքները կարող են լինել ցանկացած իրական թիվ՝ (0,1) միջակայքից, հետևաբար ՝ 0.173... և 0.689... արժեքները նույնպես վավեր ելքեր են:

<u>Նեյրոնային ցանցերի կառուցվածքը</u>

Ենթադրենք, ունենք հետևյալ ցանցը.

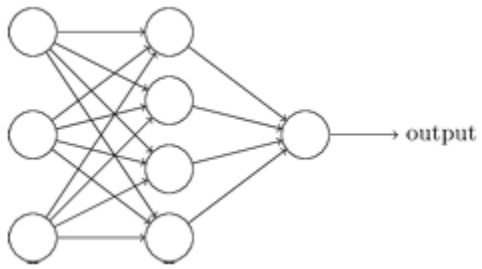

Ինչպես նշվեց ավելի վաղ, այս ցանցի առաջին շերտը կոչվում է մուտքային շերտ, իսկ շերտի ներսում գտնվող նեյրոնները կոչվում են մուտքային նեյրոններ: Վերջին կամ ելքային շերտը պարունակում է ելքային նեյրոններ կամ, ինչպես այս դեպքում, մեկ ելքային նեյրոն: Միջին շերտը կոչվում է թաքնված շերտ, քանի որ այս շերտի նեյրոնները ոչ մուտք են, ոչ էլ ելք: Վերևում նշված ցանցն ունի միայն մեկ թաքնված շերտ, բայց որոշ ցանցեր ունեն բազմաթիվ թաքնված շերտեր: Օրինակ, հետևյալ չորս շերտանոց ցանցն ունի երկու թաքնված շերտ.

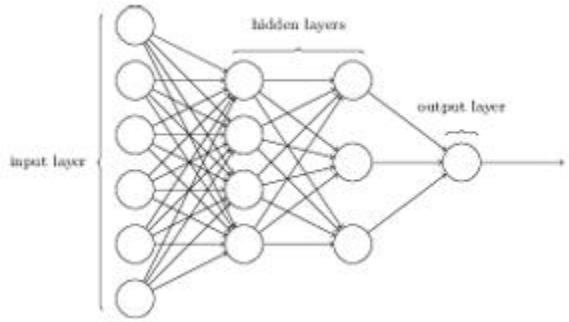

Նման բազմաշերտ ցանցերը երբեմն կոչվում են բազմաշերտ պերսեպտրոններ կամ MLP-ներ (multilayer perceptrons), չնայած դրանք կազմված են սիգմոիդ նեյրոններից, ոչ թե պերսեպտրոններից:

Ենթադրենք, մենք փորձում ենք որոշել, արդյո՞ք ձեռագիր պատկերը "9" է, թե ոչ: Ցանցը նախագծելու բնական ձևը պատկերի պիքսելների ինտենսիվությունները մուտքային նեյրոնների մեջ կոդավորելն է: Եթե պատկերը 64x64 մոխրագույն պատկեր է, ապա մենք կունենանք 4,096 = 64 × 64 հատ մուտքային նեյրոններ, որոնց ինտենսիվությունները համապատասխանաբար մասշտաբավորված են 0-ից մինչև 1: Ելքային շերտը կունենա միայն մեկ նեյրոն, որի արժեքը՝

- եթե փոքր է 0.5-ից, ապա "մուտքային պատկերը 9 չէ",
- եթե մեծ է 0.5-ից, ապա "մուտքային պատկերը 9 է":

Մինչ այժմ նկարագրված էին նեյրոնային ցանցեր, որոնցում՝ մի շերտի ելքային արժեքը օգտագործվում է, որպես հաջորդ շերտի մուտքային արժեք: Նման ցանցերը կոչվում են առաջընթաց (feedforward) նեյրոնային ցանցեր: Սա նշանակում է, որ ցանցում ցիկլեր չկան՝ տեղեկատվությունը միշտ առաջ է տարվում (fed forward), երբեք հետ չի տարվում (fed back): Եթե մենք դիտարկեինք ցիկլեր, ապա կունենայինք իրավիճակներ, որտեղ σ ֆունկցիայի մուտքը կախված կլիներ ելքից:

Սակայն կան արհեստական նեյրոնային ցանցերի այլ մոդելներ, որոնցում հետադարձ (feedback) ցիկլերը հնարավոր են: Այս մոդելները կոչվում են ռեկուրենտ նեյրոնային ցանցեր: Այս մոդելներում գաղափարը հետևյալն է՝ ունենալ նեյրոններ, որոնք ակտիվ են ժամանակի սահմանափակ տևողությամբ, մինչև պասիվ դառնալը: Այդ ակտիվությանը կարող է խթանել մյուս նեյրոններին, որոնք կարող են սահմանափակ ժամկետով ակտիվանալ:

Ռեկուրենտ ցանցերը շատ ավելի մոտ են մարդու ուղեղի աշխատանքի տրամաբանությանը, քան առաջընթաց (feedforward) ցանցերը: Ռեկուրենտ ցանցերը կարող են լուծել կարևոր խնդիրներ, որոնք կարող են մեծ դժվարությամբ լուծվել առաջընթաց ցանցերով:

<u>Ձեռագիր թվերը դասակարգելու պարզ ցանց</u>

Ձեռագիր թվերի ճանաչման խնդիրը բաժանենք երկու ենթախնդիրների: Նախ, գտնենք մի եղանակ, որով պատկերը, որը պարունակում է բազմաթիվ թվեր, կկարողանանք բաժանել առանձին պատկերների հաջորդականության, որոնցից յուրաքանչյուրն ունի մեկ թիվ: Օրինակ, հետևյալ պատկերը.

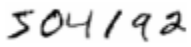

բաժանենք 6 առանձին պատկերների.

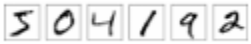

Երբ պատկերը սեգմենտացվում է, ծրագիրը պետք է դասակարգի առանձին նիշերից յուրաքանչյուրը: Առանձին թվերը ճանաչելու համար մենք կօգտագործենք երեք շերտ պարունակող նեյրոնային ցանց.

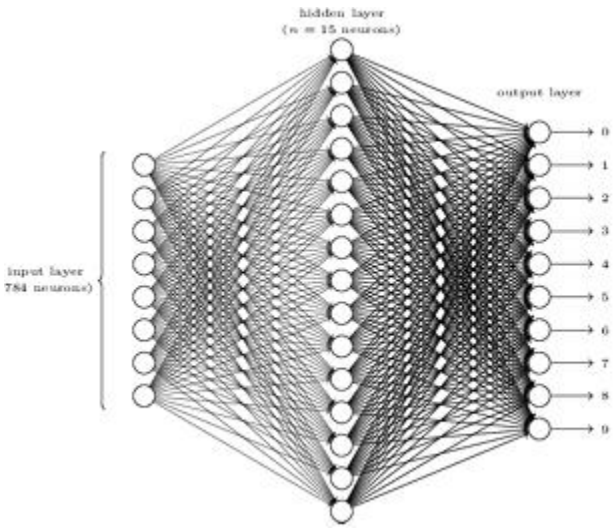

- Ցանցի մուտքային շերտը պարունակում է նեյրոններ, որոնք կոդավորում են մուտքային պիքսելների արժեքները: Ցանցի ուսուցման տվյալները կազմված են բազմաթիվ սկանավորված ձեռագիր թվերի 28x28 պիքսելային պատկերներից, և այդպիսով մուտքային շերտը պարունակում է 784 = 28 × 28 հատ նեյրոն: Մուտքային

պիքսելները մոխրագույն են: 0.0 արժեքը ներկայացնում է սպիտակի, 1.0 արժեքը՝ սևի, և միջին արժեքները՝ աստիճանաբար մգացող մոխրագույնի երանգներ:

- Ցանցի երկրորդ շերտը թաքնված շերտ է: Նշանակենք այս թաքնված շերտում գտնվող նեյրոնների քանակը n-ով, և դիտարկենք տարբեր արժեքներ n-ի համար: Օրինակում դիտարկվում է փոքր թաքնված շերտ, որը պարունակում է ընդամենը n = 15 նեյրոն:
- Ցանցի ելքային շերտը պարունակում է 10 նեյրոն: Եթե առաջին նեյրոնը ակտիվ է, այսինքն՝ ունի ելք ≈ 1, ապա դա ցույց կտա, որ ցանցը համարում է, որ թիվը 0 է: Եթե երկրորդ նեյրոնն է ակտիվ, ապա դա ցույց կտա, որ ցանցը համարում է, որ թիվը 1 է: Եվ այսպես շարունակ: Մի փոքր ավելի ճշգրիտ, մենք համարակալում ենք ելքային նեյրոնները 0-ից մինչև 9, և պարզում ենք, թե որ նեյրոնն ունի ամենաբարձր ակտիվացման արժեքը:

Ի վերջո, ցանցի նպատակը մեզ ասելն է, թե որ թիվն է (0, 1, 2, …, 9) համապատասխանում մուտքային պատկերին:

<u>Գրադիենտային վայրէջքի մեթոդ</u>

Որպեսզի ցանցը սովորի ճանաչել թվերը, անհրաժեշտ է ուսուցման տվյալների հավաքածու (training data set):

Նշանակենք համապատասխան ցանկալի ելքը y = y(x)-ով, որտեղ y -ը 10-չափային վեկտոր է (կա 10 հավանական թվանշան): Օրինակ, եթե որոշակի x ուսուցման պատկեր, պատկերում է 6, ապա $y(x) = (0,0,0,0,0,0,1,0,0,0)^T$ -ն ցանցի ցանկալի ելքն է: Նշենք, որ T-ն այստեղ տրանսպոնացման գործողությունն է, որը տողային վեկտորը դարձնում է սյունային վեկտոր:

Անհրաժեշտ է այնպիսի ալգորիթմ, որը թույլ կտա մեզ գտնել կշիռներն ու շեղումներն այնպես, որ ցանցի ելքը մոտենա y(x) -ին բոլոր ուսուցման x մուտքերի համար: Որպեսզի գնահատենք, թե որքան լավ կարող ենք հասնել այս նպատակին, սահմանենք նպատակային ֆունկցիա.

$$C(\omega, b) = \frac{1}{2n}\sum_{x}\|y(x) - a\|^{2} \qquad (8)$$

Այստեղ, նշանակում ենք.

- w -ով՝ ցանցի բոլոր կշիռները,
- b-ով՝ բոլոր շեղումները,
- n-ով՝ ուսուցման մուտքի տվյալների ընդհանուր քանակը,
- a-ով՝ ցանցի ելքերի վեկտորը, երբ x-ը մուտքագրվում է, և գումարը կատարվում է բոլոր ուսուցման մուտքերի x-ի վրա:

Ակնհայտ է, որ a ելքը կախված է x-ից, w-ից և b-ից: $\| v \|$ -ով նշանակում ենք v վեկտորի երկարության ֆունկցիան: Նշանակենք C-ն՝ քառակուսի նպատակային ֆունկցիա (այն հայտնի է նաև, որպես միջին քառակուսի սխալ կամ պարզապես MSE): Դիտարկելով քառակուսի նպատակային ֆունկցիան, կարող ենք տեսնել, որ C(w,b) -ն ոչ բացասական է, քանի որ գումարի յուրաքանչյուր անդամ ոչ բացասական է: Ավելին, C(w,b) -ն նվազում է, այսինքն՝ $C(w,b) \approx 0$, հենց այն ժամանակ, երբ y(x)-ը մոտավորապես հավասար է ելքին՝ a-ին, բոլոր ուսուցման x մուտքերի համար: Այսպիսով, կարող ենք ասել, որ ուսուցման ալգորիթմը աշխատանքը կատարել է բարեհաջող, եթե այն կարող է գտնել կշիռները և շեղումներն այնպես, որ՝ C(w,b) ≈ 0: Նույն տրամաբանությունը գործում է նաև հակառակ դիտարկման դեպքում, այն լավ չի աշխատում, երբ C(w,b)-ն մեծ է՝ y(x)-ը մոտ չէ a ելքին մեծ քանակի x մուտքերի համար: Այսպիսով, ուսուցման ալգորիթմի նպատակը կլինի նվազեցնել C(w,b) -ն, որպես կշիռների և շեղումների ֆունկցիա: Այլ կերպ ասած, մենք ցանկանում ենք գտնել կշիռների և շեղումների մի հավաքածու, որը C(w,b) -ն կդարձնի հնարավորինս փոքր: Օրինակ, տրված է բազմաթիվ փոփոխականների ֆունկցիա, և մենք ցանկանում ենք նվազեցնել այդ ֆունկցիան: Դրա համար դիտարկենք գրադիենտային վայրէջքի մեթոդը: